

INSTITUTO POLITÉCNICO NACIONAL

ESCUELA SUPERIOR DE CÓMPUTO

LICENCIATURA EN CIENCIA DE DATOS



UNIDAD DE APRENDIZAJE:

ANÁLISIS DE SERIES DE TIEMPO

PROFESORA:

GUADALUPE ANA GABRIELA MARTÍNEZ HERNÁNDEZ

Proyecto

Airline Baggage Complaints

GRUPO:

6AV1

PRESENTAN:

Huerta Rodríguez Sofía

Zhang Tan Rubi

Ciudad de México, a 26 de junio de 2026.

TABLA DE CONTENIDO

AVANCE 1 1

I. CONTEXTO DEL DATASET 1

II. GRÁFICA DE SERIE DE TIEMPO ORIGINAL 1

III. VARIABLE OBJETIVO 1

IV. FORMATO DE DATOS Y UNIDADES 2

V. RANGO DE TIEMPO Y UNIDAD DE MUESTREO 3

VI. VALORES NULOS 3

VII. ANÁLISIS ESTADÍSTICO 3

VIII. ANÁLISIS DE COMPONENTES 4

VIII.I. COMPONENTE DE TENDENCIA 5

VIII.II. COMPONENTE ESTACIONAL 5

VIII.III. COMPONENTE RESIDUAL 6

IX. ENLACE DE NOTEBOOK 6

AVANCE 2 6

I. MAPA DE CALOR DE CORRELACIÓN 6

II. GRÁFICA ACF 7

III. GRÁFICA PACF 7

IV. ANÁLISIS DE RESULTADOS 8

V. SUGERENCIA DE ORDEN DE MODELOS 8

AVANCE 3 10

I. RECORTE DE LA SERIE DE TIEMPO 10

II. PRUEBAS ESTADÍSTICAS DE ESTACIONAREIDAD 11

III. ANÁLISIS DE RESULTADOS 12

IV. TRANSFORMACIONES 13

V. VERIFICACIÓN DE ESTACIONAREIDAD DESPUÉS DE TRANSFORMACIONES 15

VI. ANÁLISIS DE CORRELACIÓN 16

VII. PROPUESTA DE ORDEN PARA MODELOS AR, MA O ARMA 18

AVANCE 4 19

I. IMPLEMENTACIÓN DE MODELOS 19

II. PRUEBA DE AUTOCORRELACIÓN DE RESIDUOS 20

III. COMPARACIÓN DE MODELOS Y SELECCIÓN 21

IV. ANÁLISIS DEL COMPONENTE ALEATORIO: PRUEBA ARCH-LM 22

AVANCE 5 24
I. MODELO SARIMA 24
II. PROPUESTA DE MODELOS SARIMA 26
III. AJUSTE Y COMPARACIÓN DE MODELOS SARIMA 27
IV. DIAGNÓSTICO DEL MEJOR MODELO SARIMA 27
V. PRONÓSTICO, MÉTRICAS Y VALIDACIÓN CRUZADA 29
CONCLUSIONES 32

AVANCE 1

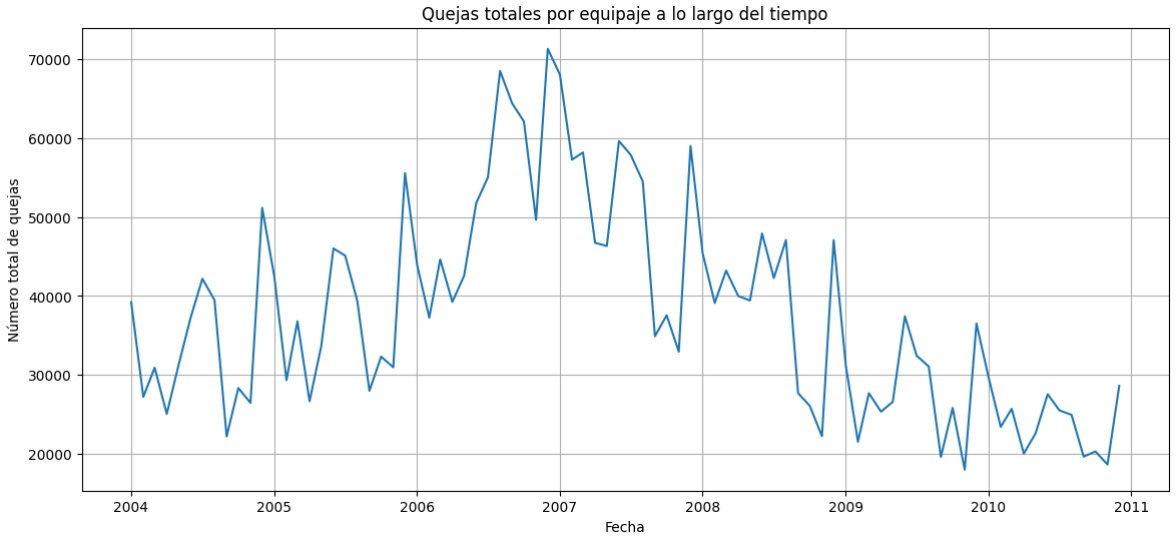
I. CONTEXTO DEL DATASET

El transporte aéreo conlleva de manera inevitable incidencias de operación, tales como: vuelos retrasados o cancelados por condiciones meteorológicas, fallas mecánicas o huelgas laborales, también, perdidas, daños o extravíos de equipaje. Muchas aerolíneas cobran por las maletas facturadas, por lo que los problemas con el equipaje pueden resultar principalmente costosos, tanto económicamente, como en la fidelidad de los clientes con la aerolínea, ya que las aerolíneas tienen la responsabilidad de entregar las maletas en el domicilio del pasajero.

En este contexto, las aerolíneas de Estados Unidos reportan al gobierno federal estadísticas de operación (retrasos, cancelaciones, sobreventa de boletos, equipajes, etc.). Esta información es publicada para el público en general.

El presente dataset muestra los reportes mensuales de tres aerolíneas: United Airlines, American Eagle y Hawaiian Airlines.

II. GRÁFICA DE SERIE DE TIEMPO ORIGINAL



III. VARIABLE OBJETIVO

La variable objetivo del dataset es Baggage, la cual representa el número total de quejas relacionadas con equipaje reportadas por los pasajeros, como el robo de contenido de equipaje, o por equipaje perdido, dañado o extraviado por la aerolínea

en ese mes del año. Consideramos esta variable ya que es relevante para el análisis de la serie de tiempo, porque permite analizar cómo evolucionan las quejas a lo largo del tiempo e identificar patrones de tendencia, estacionalidad y variaciones irregulares.

IV. FORMATO DE DATOS Y UNIDADES

Todas las variables numéricas (Baggage, Scheduled, Cancelled y Enplaned) son valores enteros positivos sin unidad media, es decir, son valores discretos.

Las columnas del dataset son:

Nombre	Descripción	Tipo	Unidades / Dominio
Airline	Nombre de la aerolínea a la que corresponden los datos del mes	Categórica	"American Eagle", Hawaiian", "United"
Date	Fecha del período de reporte	Temporal (datetime)	Mes y año en formato MM/YYYY
Month	Número del mes del año al que corresponden los datos	Numérica (entero)	Número del mes (1 = enero, 12 = diciembre)
Year	Año del período de reporte	Numérica (entero)	Año calendario (2004-2010)
Baggage	Número total de quejas relacionadas con el manejo del equipaje	Numérica (entero)	Número total de quejas por equipaje ese mes
Scheduled	Número de vuelos que estaban programados para operar en ese mes	Numérica (entero)	Número total de vuelos programados ese mes
Cancelled	Número de vuelos que fueron cancelados en ese mes	Numérica (entero)	Número total de vuelos cancelados ese mes
Enplaned	Número total de pasajeros que abordaron vuelos de esa aerolínea en ese mes	Numérica (entero)	Número total de pasajeros que abordaron ese mes

El dataset está estructurado en formato tabular (CSV), con observaciones agregadas de manera mensual. Cada fila corresponde a una aerolínea en un mes específico, esto nos permite realizar tanto análisis individuales por aerolínea como agregaciones totales para obtener una serie temporal global.

V. RANGO DE TIEMPO Y UNIDAD DE MUESTREO

El periodo analizado abarca desde enero de 2004 hasta diciembre de 2010, lo que representa un total de 7 años completos (84 meses) por cada aerolínea. La unidad de muestreo es mensual, lo que lo hace adecuado para aplicar modelos con periodicidad anual (periodo = 12).

Se trata de un rango continuo, sin interrupciones en la secuencia temporal, lo cual es ideal para el análisis de series de tiempo.

Parámetro	Valor
Inicio	Enero del 2004
Fin	Diciembre del 2010
Duración total	7 años (84 meses)
Frecuencia	Mensual
Número de aerolíneas	3
Total de observaciones	252 filas

VI. VALORES NULOS

El dataset no contiene valores faltantes o nulos, todas las 8 columnas contienen 252 valores no nulos cada una. Por lo tanto, no es necesario aplicar ningún proceso de imputación o limpieza.

VII. ANÁLISIS ESTADÍSTICO

Se calcularon las estadísticas descriptivas sobre el dataset para todas las variables numéricas. Sin embargo, solo se realizó el análisis estadístico de la variable objetivo Baggage.

	Date	Month	Year	Baggage	Scheduled	Cancelled	Enplaned
count	252	252	252	252	252	252	2.52E+02
mean	08:34.3	6.5	2007	12613.5079	28128.0079	703.761905	2.20E+06
min	01/01/2004 00:00	1	2004	1033	3553	0	4.23E+05
25%	23/09/2005 12:00	3.75	2005	1910.5	5565.75	25.75	6.87E+05
50%	16/06/2007 00:00	6.5	2007	12224	36696	533	1.39E+06
75%	08/03/2009 18:00	9.25	2009	19359.25	42162.5	1078.5	4.11E+06
max	01/12/2010 00:00	12	2010	41787	50837	3712	6.14E+06

std	NaN	3.458922	2.00398	9993.30717	17092.0879	746.020368	1.79E+06

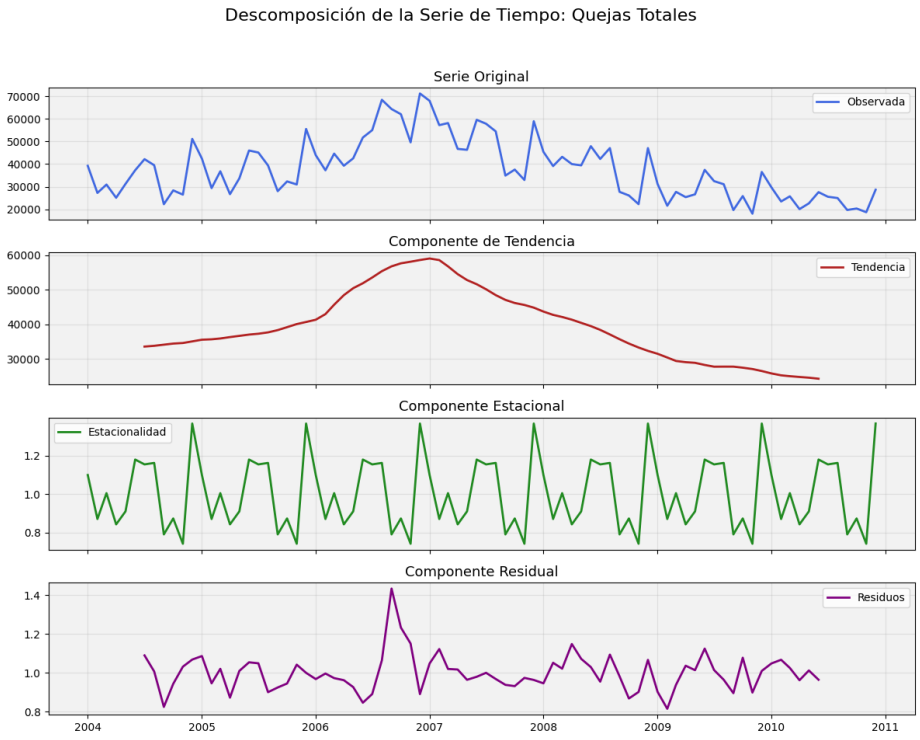
El periodo comprendido del dataset es de enero del 2004 hasta diciembre de 2010, con un promedio de 12,614 quejas por mes. La media y la mediana son similares (12,613 vs 12,224), lo que indica que la distribución no está extremadamente sesgada. Sin embargo, la desviación estándar (9,993) es bastante alta en comparación con la media, lo que indica alta variabilidad mensual en el número de quejas de un mes a otro.

El rango está desde 1,033 hasta 41,787 quejas mensuales. La diferencia entre el 75º percentil (19,359) y el máximo (41,787) sugiere picos extremos de quejas.

VIII. ANÁLISIS DE COMPONENTES

Se realizó la descomposición sobre la serie de tiempo con 12 periodos, dado que los datos son mensuales y se esperan ciclos anuales.

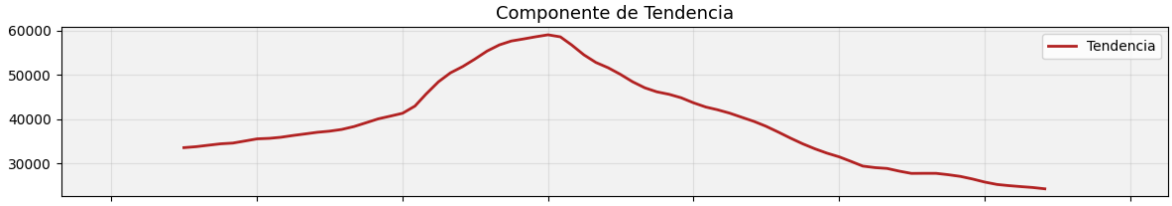
Se aplicó una descomposición multiplicativa (Serie = Tendencia × Estacionalidad × Residuo) debido a que la serie presenta una tendencia con cambios de nivel muy marcados: los picos y valles son mayores cuando el volumen de quejas es alto (2006–2007) y se reducen notablemente cuando baja (2009–2010). Debido a estas tendencias, este modelo es preferible ya que permite que las fluctuaciones estacionales se expresen como proporciones del nivel actual de la serie, capturando mejor la relación entre ambos componentes.



VIII.I. COMPONENTE DE TENDENCIA

La tendencia muestra un crecimiento cerca de 33,000 quejas mensuales a principios de 2004, hasta llegar a su punto más alto entre 57,000 y 58,000 quejas al mes en 2007. A partir de ese punto disminuye de forma constante hasta llegar a 26,000 quejas al mes al finalizar el periodo en 2010.

Este comportamiento muestra la expansión de operaciones aéreas que se dieron antes del 2008 o posibles problemas operacionales de las aerolíneas. La disminución posterior puede ser a causa de una posible crisis financiera mundial o mejoras en los procesos de manejo de equipaje, lo que generó una reducción en el tráfico de pasajeros o que se implementaron mejoras operativas para disminuir las quejas por equipajes perdidos, dañados o robados.

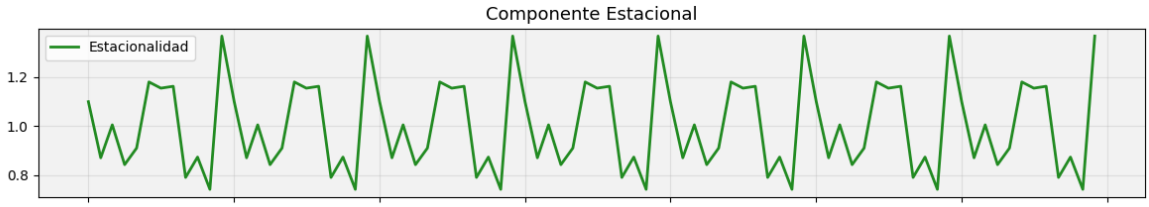


VIII.II. COMPONENTE ESTACIONAL

La estacionalidad se manifiesta como índices proporcionales alrededor del 1.0 debido a que es un modelo multiplicativo. Se observan picos de hasta 1.35, lo que significa un 35% más de quejas en comparación con la tendencia, durante los meses de verano de junio a agosto, que coincide con la época de más demanda de vuelos en Estados Unidos.

Los valles se reducen aproximadamente entre 0.78 y 0.80, es decir, un 20% menos que la tendencia en los meses de invierno de enero a febrero, donde hay una disminución del número de pasajeros.

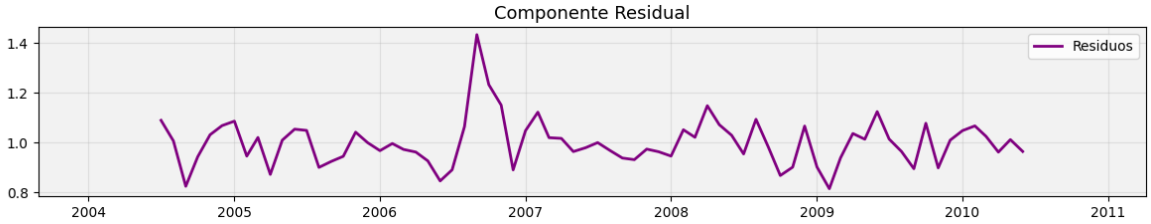
Se observan picos regulares que sugieren meses específicos con más problemas de equipaje por temporadas altas de viaje como en verano o festividades. El patrón es consistente y se repite de manera idéntica en todos los años del periodo, lo que confirma una estacionalidad anual muy definida.



VIII.III. COMPONENTE RESIDUAL

Se observa un comportamiento general estable entre 0.8 y 1.2, no obstante, se identifica un pico significativo en 2007 que supera 1.4, equivalente a un 42% de exceso no capturado por la tendencia ni la estacionalidad.

Este valor extremo podría estar relacionado con eventos extraordinarios, por ejemplo, alteraciones regulatorias, incidentes operativos a gran escala o variaciones inusuales en el volumen de operaciones de las aerolíneas durante ese periodo. En términos generales, el modelo multiplicativo explica bien la serie, ya que los residuos son relativamente pequeños la mayor parte del tiempo.



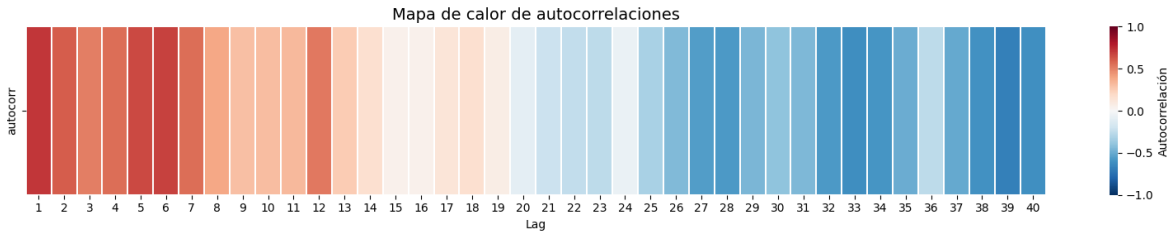
IX. ENLACE DE NOTEBOOK

https://colab.research.google.com/drive/1Ws5UnrdSSi5jwf6qu1nbotJDUaEjUEnZ?usp=sharing

AVANCE 2

I. MAPA DE CALOR DE CORRELACIÓN

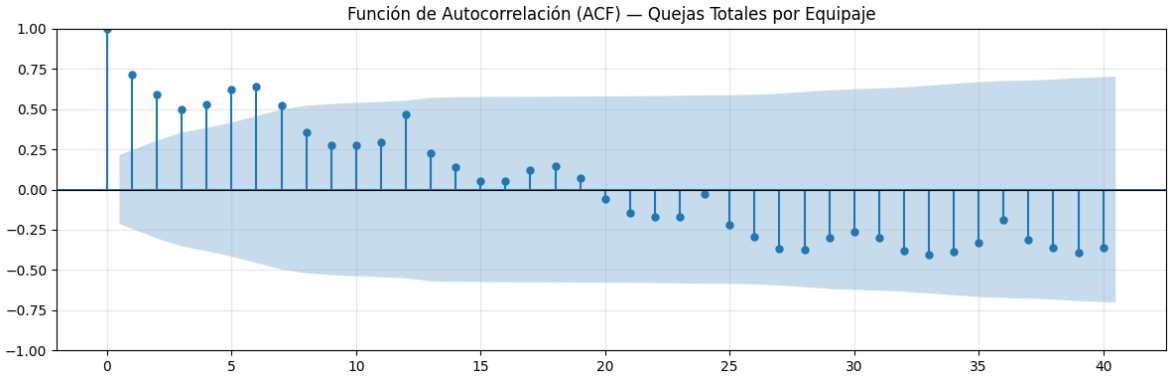
El mapa de calor muestra una transición de correlaciones positivas altas en los primeros rezagos (lags 1 al 12, con valores cercanos a 0.8) hacia valores negativos a partir del lag 20. Esto confirma que la serie tiene **memoria temporal fuerte** y que la dependencia positiva se mantiene durante aproximadamente un año, lo cual es consistente con la estacionalidad anual identificada en el análisis de componentes.



II. GRÁFICA ACF

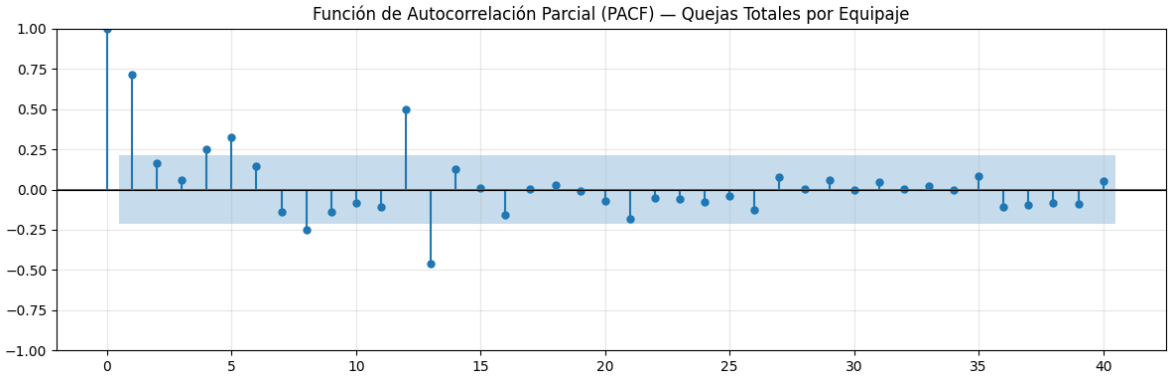
En la gráfica de la función de autocorrelación se muestra que los lags del 1 al 14 están fuera de la zona de confianza con valores altos desde 0.75 que van decayendo gradualmente. No se observa un corte abrupto, ya que la ACF decae de forma lenta y gradual.

A partir del lag 20 los valores se vuelven negativos, lo que refleja la tendencia decreciente después del 2007 que se observó anteriormente.



III. GRÁFICA PACF

La gráfica de la función de autocorrelación parcial muestra que hay un pico alto y significativo en lag 1, indicando una fuerte dependencia directa del valor actual con el mes anterior. Después, las correlaciones parciales decaen rápidamente a valores pequeños (positivos y negativos alternados), con algunos lags significativos aislados. En el lag 12 se observa un pico positivo grande y en el lag 13 un pico negativo grande, lo que demuestra una dependencia directa con el mismo mes del año anterior.



IV. ANÁLISIS DE RESULTADOS

Mapa de calor de autocorrelaciones

Para las quejas totales mensuales de equipaje entre 2004 y 2010, el mapa muestra autocorrelaciones positivas fuertes en los lags 1 al 12, lo que indica que, si en un mes determinado el número de quejas fue alto, por ejemplo, durante los picos registrados en United Airlines que supera las 30,000 quejas mensuales en algunos periodos, es muy probable que los meses siguientes también registren valores elevados. La transición hacia valores negativos a partir del lag 25 refleja que, en horizontes de más de dos años, los niveles de quejas tienden a invertirse respecto al punto de referencia.

Función de Autocorrelación (ACF)

El lag 1 arroja una autocorrelación de aproximadamente 0.74, lo que confirma una dependencia mes a mes muy fuerte en la serie de quejas. Esto es coherente con el contexto del dataset: los factores estructurales que generan quejas (tamaño de la operación, rutas, infraestructura de manejo de equipaje) no cambian de un mes al otro, por lo que el nivel de quejas de octubre, por ejemplo, anticipa bien el de noviembre. El repunte visible alrededor del lag 12 (~0.48) es particularmente relevante, indica que las quejas de un mes dado se parecen a las del mismo mes del año anterior, lo cual tiene sentido dado que el tráfico aéreo y con él el volumen de equipaje manejado sigue un ciclo anual marcado por temporadas vacacionales de verano y diciembre, periodos donde Enplaned alcanza sus máximos en las tres aerolíneas del dataset.

Función de Autocorrelación Parcial (PACF)

El pico dominante en el lag 1 (≈ 0.74) seguido de una caída rápida dentro de las bandas de confianza nos sugiere que, una vez que se controla el efecto del mes inmediato anterior, los meses más lejanos aportan poca información adicional directa. Los picos puntuales en lags 8 y 13 podrían estar relacionados con la estacionalidad del presente dataset: el lag 13 en particular refuerza la señal del lag 12 de la ACF, apuntando al ciclo anual de quejas observado en las tres aerolíneas.

V. SUGERENCIA DE ORDEN DE MODELOS

Aplicando los criterios de identificación vistos en clase, se determinó el orden tentativo de los modelos a explorar en etapas posteriores:

Criterio observado	Implicación
ACF decae lentamente sin corte abrupto	Presencia de componente AR
PACF corta después del lag 2	Orden autorregresivo: p = 2
ACF decae sin corte claro en lags bajos	Orden de media móvil: q = 1
Pico estacional significativo en PACF lag 12	Componente estacional AR: P = 1

Con base en el comportamiento conjunto de la ACF y la PACF, se proponen los siguientes modelos:

Modelo AR: La PACF presenta un corte después del lag 2, lo que según los criterios de la clase indica dependencia directa en las dos observaciones pasadas inmediatas. Esto sugiere que el nivel mensual de quejas de equipaje puede explicarse como una combinación lineal de los dos meses anteriores.

Modelo MA: La ACF decae sin un corte claro en los lags bajos, lo que refleja dependencia en innovaciones pasadas de corto plazo. Se propone un modelo de media móvil de orden 1, donde el nivel de quejas de un mes estaría influenciado por el error de predicción del mes inmediato anterior.

Modelo ARMA: Dado que ambas funciones presentan señales mixtas, PACF con corte en lag 2 y ACF con decaimiento gradual, el modelo más completo y respaldado por los criterios de la clase es un modelo ARMA, que combina la dependencia directa en observaciones pasadas con la dependencia en innovaciones, capturando así toda la estructura de dependencia temporal identificada en la serie de quejas de equipaje.

AVANCE 3

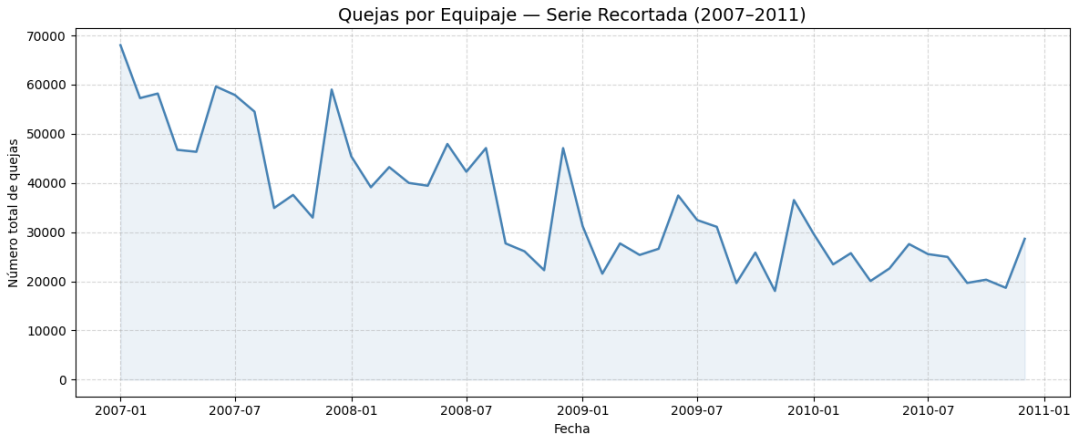
I. RECORTE DE LA SERIE DE TIEMPO

Como ya fue mencionado anteriormente, la base de datos original contiene registros mensuales de quejas por manejo de equipaje en aerolíneas de los Estados Unidos, cubriendo el periodo de enero de 2004 a diciembre de 2010, con un total de 252 observaciones distribuidas en 8 variables: aerolínea, fecha, mes, año, número de quejas por equipaje (Baggage), vuelos programados, cancelaciones y pasajeros embarcados.

Al examinar la serie completa (2004–2010) se observa un comportamiento no homogéneo a lo largo del tiempo: la serie presenta una fase de crecimiento sostenido desde 2004 hasta alcanzar un pico máximo alrededor de 2006–2007 (con valores cercanos a 70,000 quejas mensuales), seguida de una tendencia decreciente pronunciada que se extiende hasta 2010. Esta estructura en forma de "montaña" introduce una asimetría temporal que complica el modelado estadístico, ya que los mecanismos que generan la serie en la fase creciente son distintos a los de la fase decreciente.

Se realizó un recorte de la serie al período 2007–2010 con el objetivo de trabajar únicamente con la fase decreciente y estructuralmente más homogénea de la serie. Este periodo mantiene una tendencia a la baja sin cambios bruscos, evitando el quiebre que ocurre antes de 2007 y que complicaría el uso de modelos ARIMA.

Al eliminar ese cambio, la serie se vuelve más fácil de analizar con una sola diferenciación, además, coincide con eventos relevantes en la industria aérea. Trabajar con una serie más corta pero estable permite obtener resultados más confiables. En total, se utilizan 48 observaciones mensuales (enero 2007 a diciembre 2010) para el análisis.



II. PRUEBAS ESTADÍSTICAS DE ESTACIONAREIDAD

Antes de aplicar cualquier modelo de series de tiempo, es importante verificar si la serie es estacionaria, es decir, si su media, varianza y estructura de autocovarianza son constantes en el tiempo. Se aplicaron dos pruebas sobre la serie recortada (Baggage total mensual, 2007–2010): la prueba de Dickey-Fuller Aumentada (ADF) y la prueba de Ljung-Box.

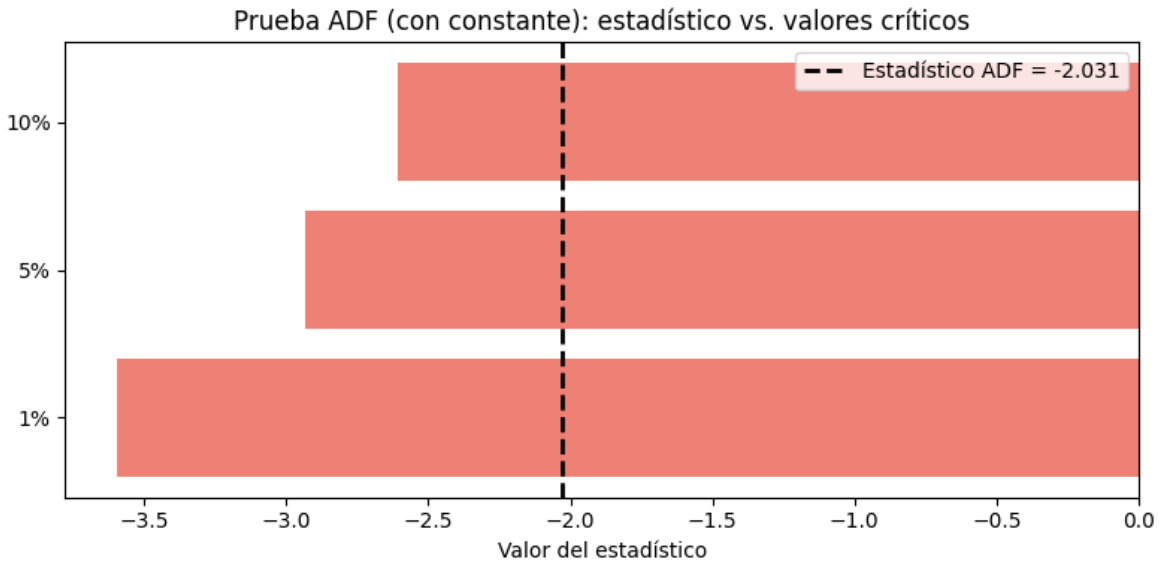
Prueba de Dickey-Fuller Aumentada (ADF)

La prueba ADF evalúa

- H_0: la serie tiene raíz unitaria (no estacionaria).
- H_1: la serie es estacionaria.

Se aplicó bajo dos especificaciones: con constante únicamente ('c') y con constante más tendencia determinista ('ct'). El número máximo de rezagos se determinó mediante la regla de Schwert:

Especificación	Estadistico ADF	p-valor	Rezagos	Conclusión
Con constante ('c')	-2.0305	0.2733	5	No se rechaza H_0: posible raíz unitaria
Constante y tendencia ('ct')	-5.2989	0.0001	2	Se rechaza H_0: serie estacionaria



Prueba de Ljung-Box:

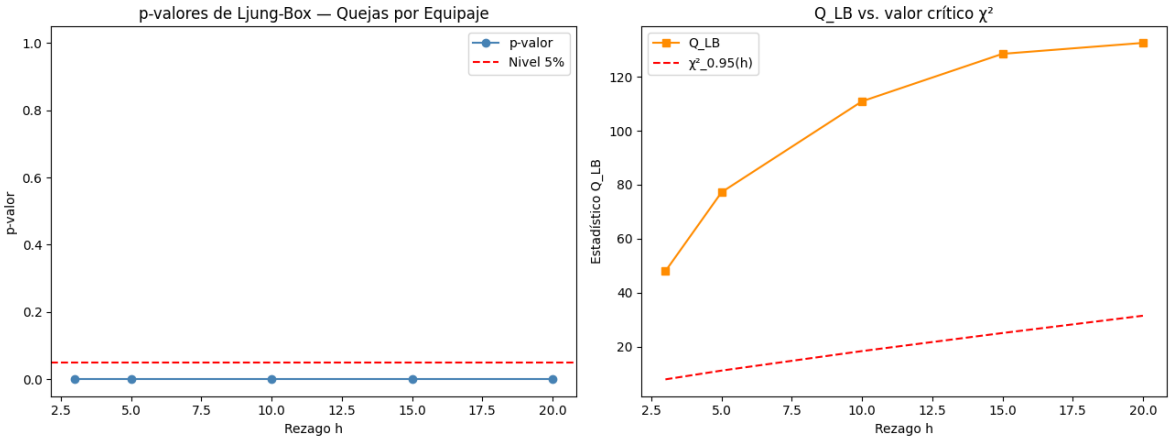
La prueba de Ljung-Box evalúa

- H_0: los primeros h rezagos de la función de autocorrelación son conjuntamente iguales a cero (ausencia de autocorrelación)
- H_1: al menos uno es diferente de cero.

El estadístico Q_LB sigue una distribución chi-cuadrado con h grados de libertad.

Los resultados obtenidos sobre la serie fueron:

Rezago h	Q_LB	p-valor	χ^2_crítico (0.95)	Conclusión
3	47.9498	0.000000	7.815	Rechaza H_0
5	77.2285	0.000000	11.070	Rechaza H_0
10	110.9338	0.000000	18.307	Rechaza H_0
15	128.5420	0.000000	24.996	Rechaza H_0
20	132.5910	0.000000	31.410	Rechaza H_0



III. ANÁLISIS DE RESULTADOS

Análisis de resultados ADF

Con constante ('c'): El estadístico ADF de -2.0305 no supera (en valor absoluto) los valores críticos al 1% (-3.597), 5% (-2.933) ni 10% (-2.605). El p-valor de 0.2733 es muy superior al nivel de significancia del 5%, por lo que **no se rechaza H_0**: la serie tiene raíz unitaria y es no estacionaria cuando solo se considera una media diferente de cero.

Con constante y tendencia ('ct'): El estadístico ADF de -5.2989 sí supera los valores críticos al 1% (-4.175), 5% (-3.513) y 10% (-3.187). El p-valor de 0.0001 es

significativo, por lo que **se rechaza H_0**: la serie es estacionaria alrededor de una tendencia determinista.

Interpretación: Los resultados contradictorios entre ambas especificaciones revelan que la serie tiene una tendencia determinista decreciente. Es estacionaria solo cuando se incluye esa tendencia en el modelo, pero no en niveles puros. Esto indica que la tendencia es el componente no estacionario dominante y que se requiere una transformación para eliminarla antes de modelar.

Análisis de resultados de Ljung-Box

En todos los rezagos evaluados (3, 5, 10, 15 y 20), los estadísticos Q_LB son extremadamente elevados y los p-valores son iguales a cero, muy por debajo del nivel de significancia del 5%. Esto lleva a rechazar H_0 en todos los casos, lo que indica:

- Autocorrelación fuerte y persistente: La serie presenta dependencia temporal significativa en todos los horizontes evaluados. Los valores de hoy están correlacionados con los de meses anteriores.
- Estructura modelable: La presencia de autocorrelación confirma que existe información en el pasado de la serie que puede ser aprovechada para modelar y pronosticar.
- Consistencia con la no estacionariedad: La autocorrelación persistente a rezagos altos (10, 15, 20) es característica de series con tendencia o raíz unitaria, lo cual es coherente con el resultado del ADF.

En conjunto, los resultados de ADF y Ljung-Box confirman que la serie original es no estacionaria con tendencia y con autocorrelación significativa, lo que hace indispensable aplicar transformaciones antes de proceder con el modelado ARIMA.

IV. TRANSFORMACIONES

Para seleccionar la transformación adecuada, se analizó visualmente el comportamiento de la varianza a lo largo del tiempo. En la serie original se observa que las oscilaciones (amplitud de los movimientos) son notablemente más grandes al inicio del período (2007), cuando los niveles de quejas son altos (~60,000–70,000), que al final (2010–2010), cuando los niveles son bajos (~20,000). Este patrón indica que la varianza no es constante, sino que decrece proporcionalmente con el nivel de la serie, fenómeno conocido como heterocedasticidad.

Con lo anterior, se aplicaron dos transformaciones en secuencia:

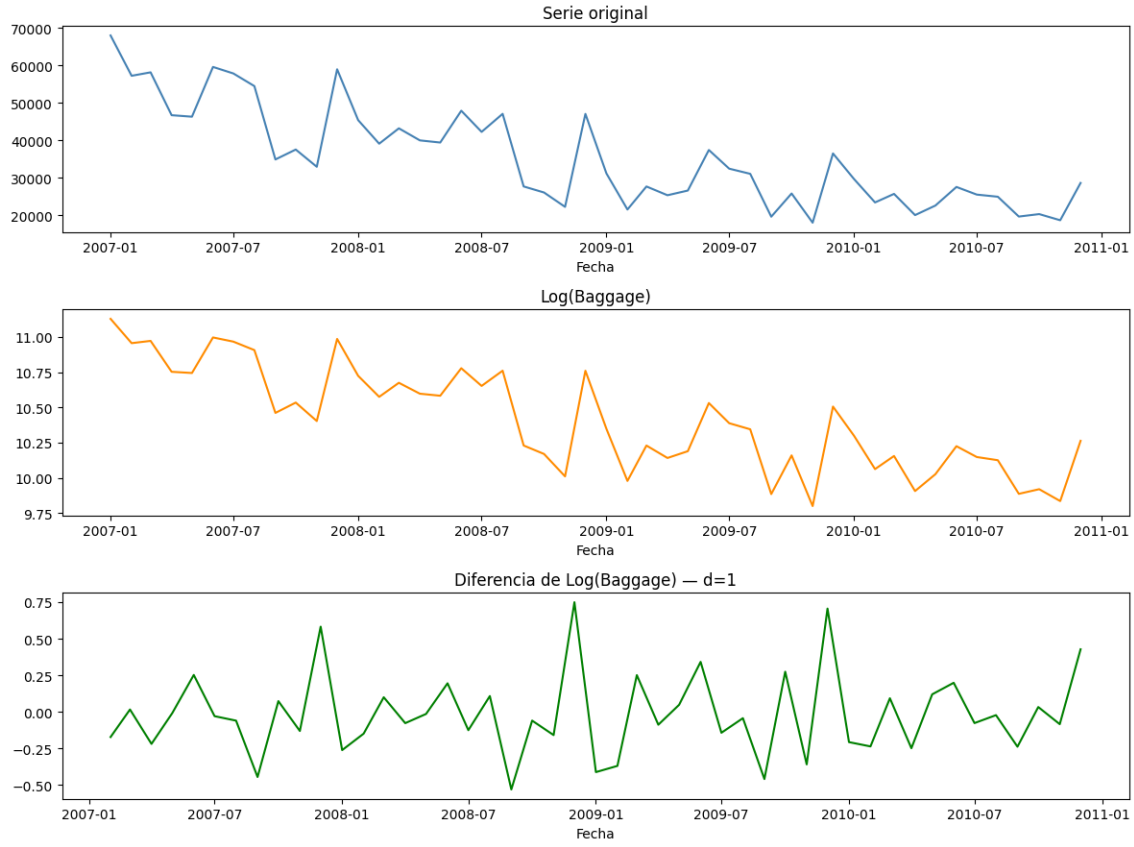
1- **Transformación logarítmica: log(Baggage_t)**

El logaritmo natural comprime los valores grandes más que los pequeños, estabilizando la varianza a lo largo del tiempo. Matemáticamente, si la varianza original crece proporcionalmente al nivel (varianza ~ nivel²), el logaritmo la convierte en aproximadamente constante. Visualmente, la serie log(Baggage) muestra oscilaciones de amplitud uniforme en todo el período, confirmando que la heterocedasticidad fue corregida.

2- Diferenciación de orden 1: ΔlogBaggage_t = log(Baggage_t) − log(Baggage_{t−1})

La diferenciación elimina la tendencia determinista detectada por el ADF. Al restar el valor del período anterior, se convierte la serie de niveles en una serie de cambios, cuya media es aproximadamente cero y que no presenta tendencia creciente ni decreciente. Además, la diferencia de logaritmos tiene una interpretación oráctica sencilla, representa cuánto cambiaron porcentualmente las quejas de un mes a otro.

Problema detectado	**Transformación aplicada**	**Efecto**
Heterocedasticidad (varianza no constante)	Logaritmo natural log(·)	Estabiliza la varianza
Tendencia decreciente (no estacionariedad)	Diferenciación d=1	Elimina la tendencia
Ambos problemas combinados	log(·) + diff()	Serie estacionaria y homocedástica



Aquí podemos observar primero la serie original con tendencia decreciente y oscilaciones de mayor amplitud al inicio del período que al final, lo que evidencia la heterocedasticidad.

Después, tras aplicar el logaritmo natural, la tendencia persiste, pero las oscilaciones ya presentan una amplitud más uniforme, indicando que la varianza fue estabilizada.

Finalmente, en el panel inferior, la diferenciación elimina la tendencia y la serie resultante oscila alrededor de cero con variabilidad constante a lo largo de todo el período, confirmando visualmente que la transformación log + diferenciación fue suficiente para obtener una serie estacionaria.

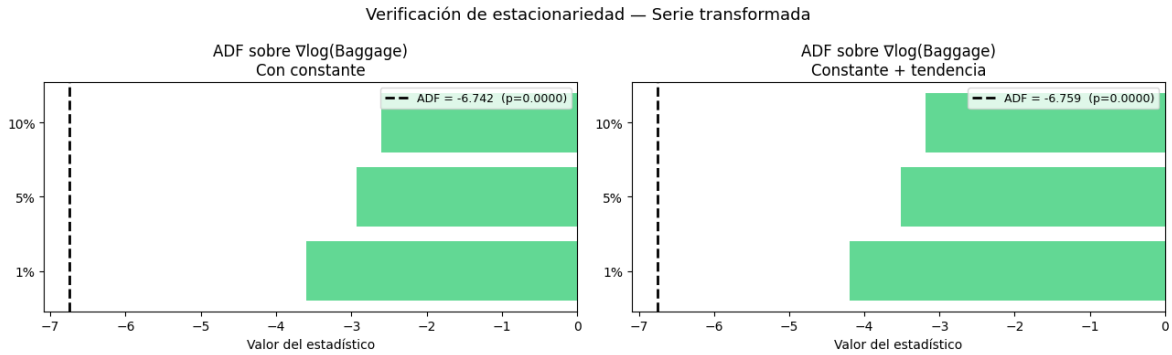
V. VERIFICACIÓN DE ESTACIONAREIDAD DESPUÉS DE TRANSFORMACIONES

Se volvió a aplicar la prueba ADF sobre la serie transformada, donde:

- H_0: la serie transformada tiene raíz unitaria (no estacionaria).
- H_1: la serie transformada es estacionaria.

La prueba dio los siguientes resultados.

Especificación	Estadistico ADF	p-valor	Rezagos	Conclusión
Con constante ('c')	-6.7424	0.0000	4	Se rechaza H_0: serie estacionaria
Constante y tendencia ('ct')	-6.7586	0.0000	4	Se rechaza H_0: serie estacionaria



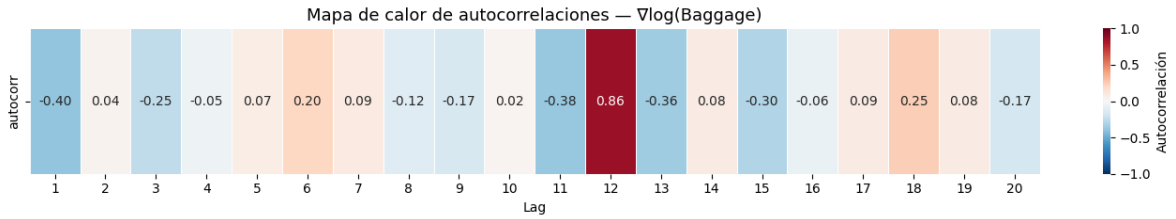
Tras la transformación, ambas especificaciones rechazan H_0, ya que el estadístico ADF cae a -6.74 (con constante) y −6.76 (con constante y tendencia), los cuales superan el umbral crítico. Los p-valores son prácticamente nulos. Esto confirma que la serie transformada es estacionaria en media y en varianza.

VI. ANÁLISIS DE CORRELACIÓN

Una vez que se verificó que la serie transformada es estacionaria, se calculó la función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF) para hasta 20 rezagos, así como un mapa de calor de autocorrelaciones que permite visualizar la estructura de dependencia.

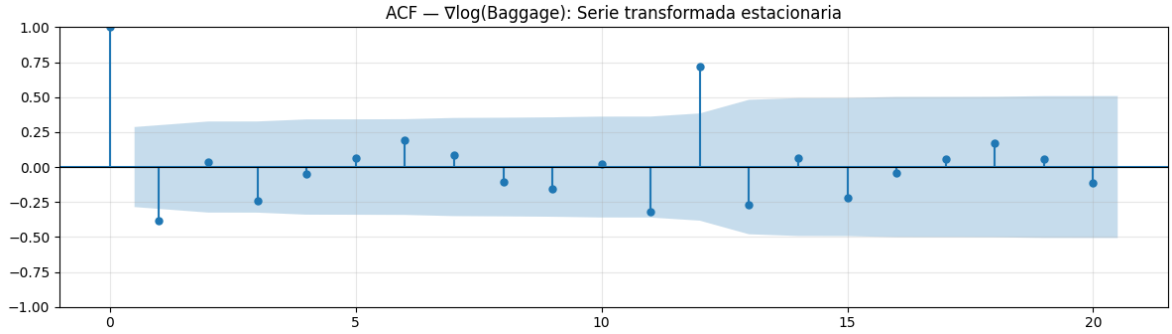
Mapa de calor de autocorrelaciones

El mapa de calor muestra un comportamiento distinto al de la serie original, en su mayoría hay autocorrelaciones moderadas o bajas. Se observa una correlación negativa significativa en el Lag 1 (-0.40), lo que sugiere una posible sobre-diferenciación. En el Lag 12, el valor es muy alto (0.86), lo que indica que la diferenciación simple (d=1) no logró eliminar la estacionalidad anual, pero sí la tendencia. La dependencia con el mismo mes del año anterior sigue siendo muy fuerte. Los valores intermedios oscilan cerca de cero o presentan correlaciones débiles.



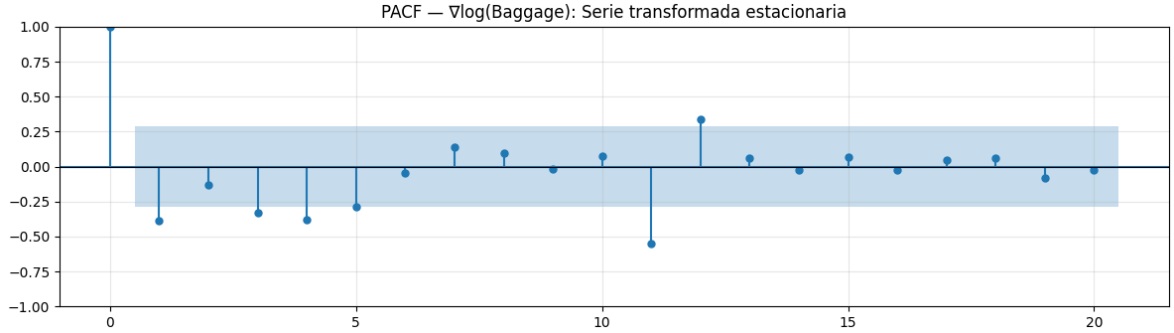
Función de Autocorrelación (ACF)

El Lag 1 muestra una barra negativa significativa que sale de las bandas de confianza, lo que indica dependencia negativa directa con el mes inmediato anterior. En el Lag 12 se presenta un pico positivo muy pronunciado que supera la zona de confianza. Esto confirma visualmente que la componente estacional anual persiste en la serie transformada. El resto de los lags se encuentran mayoritariamente dentro de la zona de confianza.



Función de Autocorrelación Parcial (PACF)

Se presentan picos significativos (negativos) en los primeros lags, lo cual es consistente con la correlación negativa observada en la ACF del Lag 1. En el Lag 11 se observa un pico negativo, que anticipa la estructura estacional. En el Lag 12 se muestra un pico positivo, asociado a la dependencia estacional directa.



VII. PROPUESTA DE ORDEN PARA MODELOS AR, MA O ARMA

Con base en el análisis del mapa de calor, la ACF y la PACF de la serie transformada ∇log(Baggage), se ajustan las propuestas de modelos debido a los siguientes patrones observados.

Criterio observado	**Implicación para el modelo**
ACF: corte abrupto después del lag 1 (valor negativo significativo)	Orden de media móvil: q = 1
PACF: decaimiento gradual con picos alternados en lags bajos	Presencia de componente AR
PACF: pico significativo en lag 1 (negativo)	Orden autorregresivo: p = 1
ACF y PACF: pico significativo en lag 12	Componente estacional SA: Q = 1 o P = 1
Transformación aplicada: log + diferenciación d = 1	Orden de integración: d = 1

Modelo AR(p): La PACF de la serie transformada tiene un pico negativo en el lag 1 seguido de un decaimiento rápido dentro de la zona de confianza, lo que sugiere una dependencia autorregresiva directa únicamente con el periodo inmediato anterior. Se propone un modelo AR(1), donde la variación logarítmica mensual de quejas puede explicarse como función lineal de la variación del mes anterior.

Modelo MA(q): La ACF muestra un corte relativamente abrupto después del lag 1 (con ese lag siendo el único claramente significativo fuera de la estacionalidad), lo que es característico de un proceso de media móvil de orden bajo. Se propone un modelo MA(1), donde la variación del mes actual está influenciada por el error de predicción del mes anterior.

Modelo ARMA(p, q): Dado que ambas funciones presentan señales mixtas (la PACF con un pico dominante en lag 1 y la ACF también con dependencia en lag 1), la combinación más adecuada es un modelo ARMA(1,1). Este modelo captura simultáneamente la dependencia con el valor pasado inmediato y con el error de predicción del mes anterior, cubriendo toda la estructura de dependencia a corto plazo identificada en la serie transformada.

AVANCE 4

I. IMPLEMENTACIÓN DE MODELOS

Se estimaron tres modelos de la familia ARIMA sobre la serie transformada log(Baggage) con orden de integración d=1, dado que la serie original requirió una diferenciación para alcanzar la estacionariedad. Los modelos estimados fueron AR(1), MA(1) y ARMA(1,1), implementados como ARIMA(1,1,0), ARIMA(0,1,1) e ARIMA(1,1,1) respectivamente.

AR(1) — ARIMA(1,1,0)

El modelo autorregresivo de orden 1 plantea que el valor actual de la serie depende linealmente del valor del período inmediato anterior. El coeficiente estimado ar.L1 = -0.3909 resultó estadísticamente significativo con un p-valor de 0.019, esto indica que la relación con el rezago 1 es real y no producto del azar. El signo negativo del coeficiente se puede interpretar como que, si las quejas aumentaron un mes, el modelo predice que tenderán a disminuir el mes siguiente, y viceversa. La varianza del error estimada fue $\sigma^2 = 0.0661$. Para los criterios de información, este modelo obtuvo AIC = 9.87 y BIC = 13.57, son los valores más altos de los tres modelos evaluados, lo que lo posiciona como el menos eficiente en términos de ajuste relativo.

MA(1) — ARIMA(0,1,1)

El modelo de medias móviles de orden 1 plantea que el valor actual de la serie está influenciado por el error de predicción del período anterior. El coeficiente ma.L1 = -0.6974 es altamente significativo (p = 0.000), con un intervalo de confianza al 95% que va de -0.854 a -0.541, sin incluir el cero, lo que refuerza la solidez del estimado. El valor negativo indica que un error positivo en el mes anterior (que las quejas fueron mayores a lo esperado) se traduce en una corrección a la baja en el mes actual. La varianza del error $\sigma^2 = 0.0566$ es la más baja de los tres modelos. Este modelo obtuvo AIC = 3.11 y BIC = 6.81, siendo los criterios más bajos de los tres, lo que lo posiciona como el modelo más adecuado para esta serie.

ARMA(1,1) — ARIMA(1,1,1)

El modelo mixto combina un componente autorregresivo y uno de medias móviles de orden 1 cada uno. Al estimar ambos coeficientes simultáneamente, el coeficiente ma.L1 = -0.7364 mantiene su significancia estadística (p = 0.000), pero el coeficiente ar.L1 = 0.1162 resulta completamente no significativo con p = 0.741, cuyo intervalo de confianza [-0.574, 0.806] incluye ampliamente el cero. Esto indica que el componente autorregresivo no aporta información adicional una vez que el componente MA está presente en el modelo, por lo que incluirlo solo incrementa la complejidad sin mejorar el ajuste. La varianza del error $\sigma^2 = 0.0562$ es muy similar

a la del MA(1), y los criterios AIC = 4.70 y BIC = 10.25 son mayores que los del MA(1), confirmando que el modelo más simple es preferible.

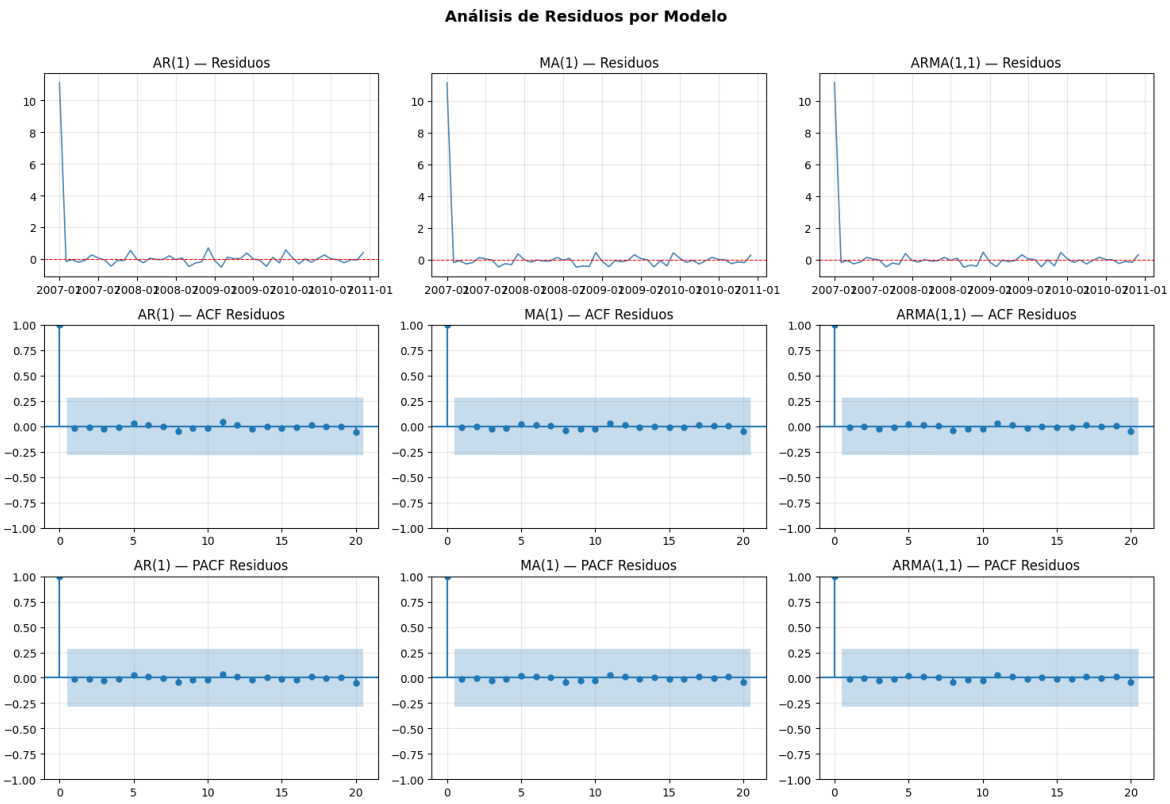
II. PRUEBA DE AUTOCORRELACIÓN DE RESIDUOS

Una vez estimados los modelos, se revisó si los residuos se comportaban como ruido blanco, es decir, si no presentaban autocorrelación. Esto es importante porque, si los residuos todavía tienen dependencia entre sí, significa que el modelo no logró capturar toda la información de la serie. Para comprobarlo se aplicó la prueba de Ljung-Box, la cual evalúa si las autocorrelaciones de varios rezagos son estadísticamente iguales a cero. La hipótesis nula (H0) establece que no existe autocorrelación en los residuos; por lo tanto, si se rechaza, indicaría que el modelo está mal especificado.

Modelo AR(1): En los rezagos evaluados (5, 10, 15 y 20), los valores del estadístico Q_{LB} fueron muy pequeños, entre 0.09 y 0.72, mientras que los p-valores fueron cercanos a 1.0 y mayores al nivel de significancia de 0.05. Por ello, no se rechaza H0 en ninguno de los casos, lo que indica que los residuos no presentan autocorrelación y pueden considerarse ruido blanco.

Modelo MA(1): Los resultados fueron similares. Los estadísticos Q_{LB} estuvieron entre 0.07 y 0.59 y los p-valores también fueron muy altos. Esto confirma nuevamente que los residuos se comportan como ruido blanco. Además, este modelo presentó los valores más pequeños de Q_{LB}, lo que sugiere que fue el que dejó menos estructura sin explicar en la serie.

Modelo ARMA(1,1): En este caso, los estadísticos también fueron pequeños, entre 0.07 y 0.56, con p-valores cercanos a 1.0 en todos los rezagos analizados. Por lo tanto, tampoco se rechaza H0 y los residuos pueden considerarse ruido blanco. Sin embargo, aunque el modelo cumple con esta condición, el coeficiente $ar.L1$ no resultó significativo, por lo que el modelo termina siendo más complejo de lo necesario.



En las gráficas de residuos en el tiempo se observa que, en los tres modelos, los residuos oscilan alrededor de cero y no muestran tendencias claras. Únicamente aparece un valor atípico al inicio del periodo (enero de 2007), visible como un pico elevado en la primera observación. Aun así, este comportamiento no afecta de manera importante el análisis, ya que el resto de los residuos se mantiene estable.

Por otra parte, las gráficas ACF y PACF de los residuos respaldan lo obtenido con la prueba de Ljung-Box, ya que todos los rezagos permanecen dentro de las bandas de confianza al 95% y no se observan picos significativos en ninguno de los modelos.

En general, los tres modelos cumplen correctamente con la prueba de autocorrelación de residuos, lo que indica que están bien especificados y logran capturar la dinámica de la serie. Sin embargo, la principal diferencia entre ellos está en qué tan eficientes y simples son.

III. COMPARACIÓN DE MODELOS Y SELECCIÓN

Para seleccionar el modelo más adecuado, se utilizaron los criterios de AIC y BIC. Como se observa en la siguiente tabla, los tres modelos fueron válidos en cuanto al diagnóstico de residuos, sin embargo, el modelo con menor AIC y BIC es el **MA(1)**

con AIC = 3.1133 y BIC = 6.8136, los cuales son los valores más bajos de los tres modelos.

Modelo	AIC	BIC
AR(1)	9.8735	13.5738
MA(1)	3.1133	6.8136
ARMA(1,1)	4.7032	10.2536

El AR(1) obtuvo los criterios más altos (AIC = 9.87, BIC = 13.57), por lo que se descarta. El ARMA(1,1) tiene valores intermedios (AIC = 4.70, BIC = 10.25), pero como su coeficiente autorregresivo no resultó significativo (p = 0.741), añadir ese parámetro no aporta nada al modelo, ya que incrementaría la complejidad del modelo sin mejorar el ajuste.

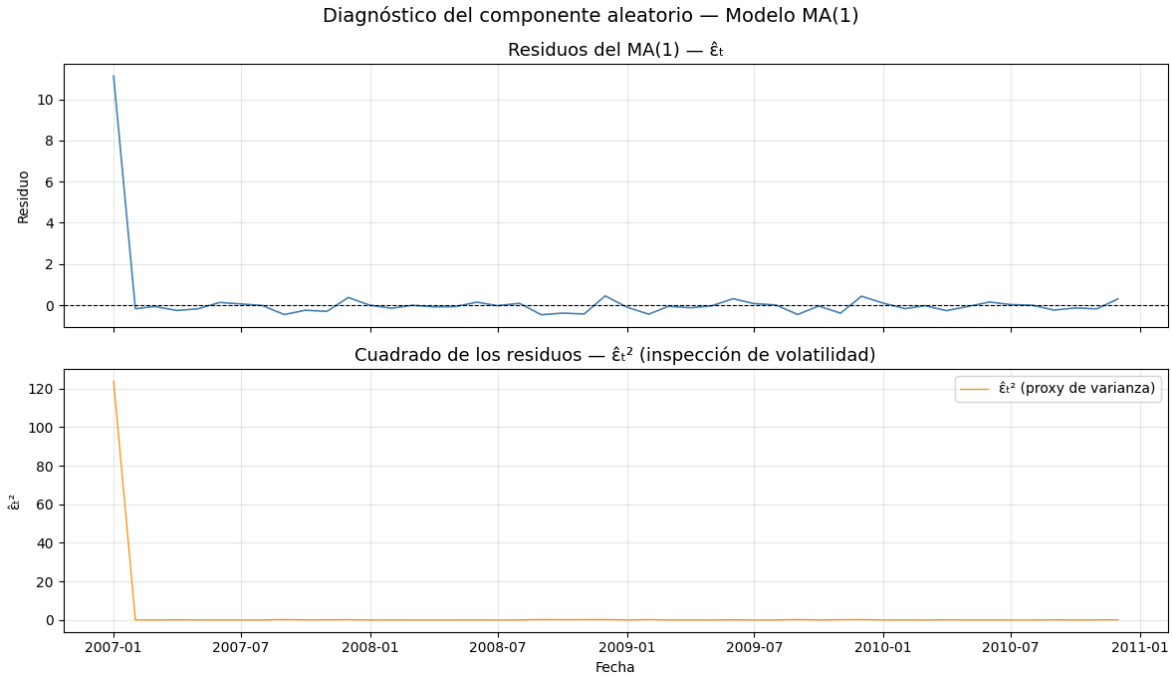
Por lo tanto, **el modelo seleccionado para representar la serie de quejas totales por equipaje en el periodo 2007–2010 es el MA(1) — ARIMA(0,1,1).** Sus residuos se comportan como ruido blanco, su único coeficiente es significativo y sus criterios de información son los menores, lo que lo convierte en el modelo más adecuado para esta serie. Esto también es consistente con lo que se observó en la ACF de la serie transformada, donde el lag 1 era el único significativo, lo cual indica un proceso MA(1).

IV. ANÁLISIS DEL COMPONENTE ALEATORIO: PRUEBA ARCH-LM

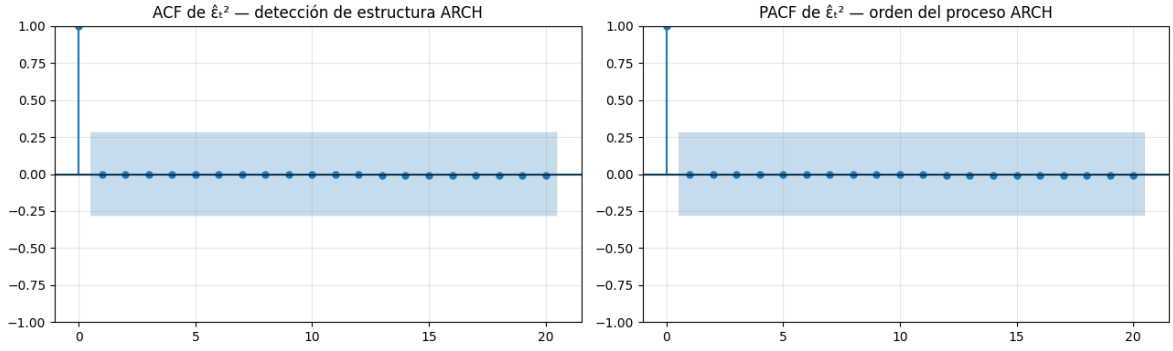
Una vez seleccionado el MA(1) como mejor modelo ARIMA, se verificó si los residuos presentaban heteroscedasticidad condicional (efectos ARCH), que implicaría que la varianza de los errores depende de sus propios rezagos pasados.

La prueba ARCH-LM (Engle, 1982) se aplicó a los residuos del MA(1) para órdenes $q \in \{1, 2, 3, 5, 10\}$:

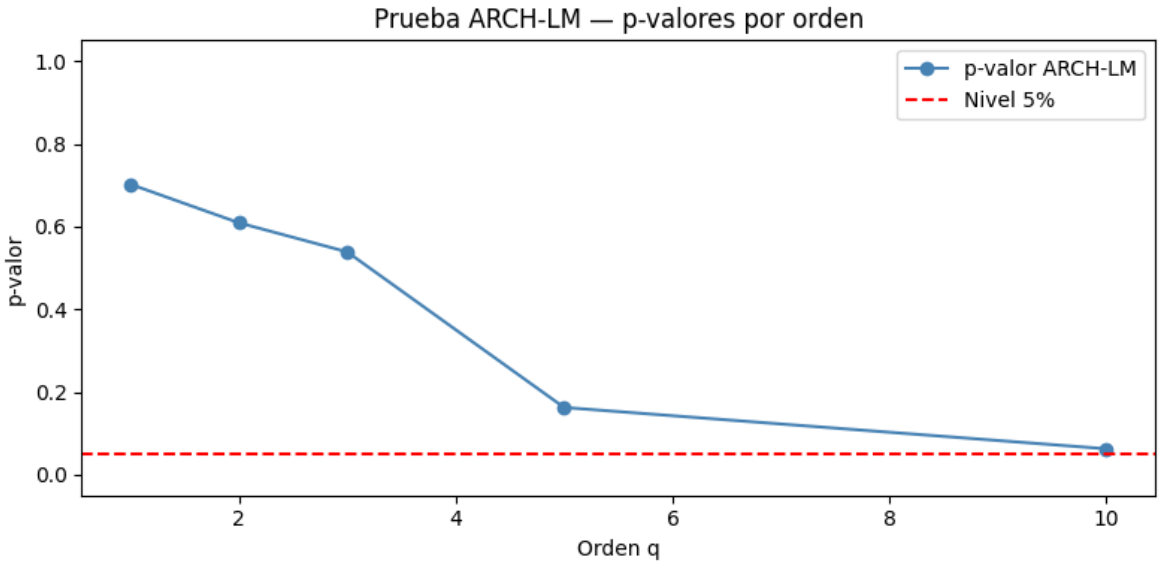
- H_0: varianza condicional constante (homocedasticidad).
- H_1: existe efecto ARCH de orden q.



Se observa un residuo atípico al inicio de la serie (enero 2007), posiblemente asociado al proceso de recorte y diferenciación. Tras ese punto, los residuos y sus cuadrados muestran comportamiento estable sin agrupamiento de volatilidad visible.



La ACF y PACF de los residuos al cuadrado no muestran autocorrelación significativa en ningún rezago, lo que indica ausencia de estructura ARCH en la varianza condicional.



Los p-valores de la prueba ARCH-LM superan el nivel de significancia del 5% para todos los órdenes evaluados ($q \in \{1,2,3,5,10\}$), por lo que no se rechaza H_0. Los residuos del MA(1) presentan varianza condicional constante (homocedasticidad), confirmando que el modelo está bien especificado y no requiere un componente GARCH.

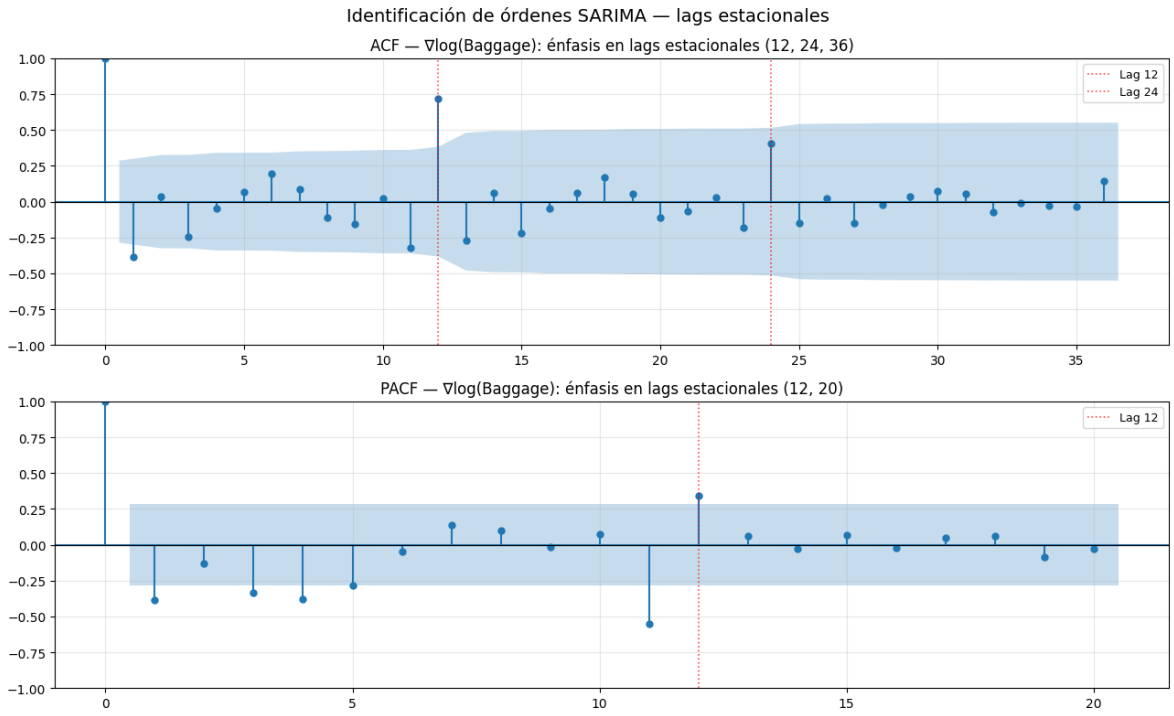
AVANCE 5

I. MODELO SARIMA

Los modelos ARIMA (AR(1), MA(1) y ARMA(1,1)) capturaron la dinámica de corto plazo y generaron residuos de ruido blanco, pero su pronóstico mostró errores elevados en los meses de septiembre y octubre (MAPE ≈ 26%). Esto sugiere un patrón estacional anual que los modelos no estacionales no pudieron capturar.

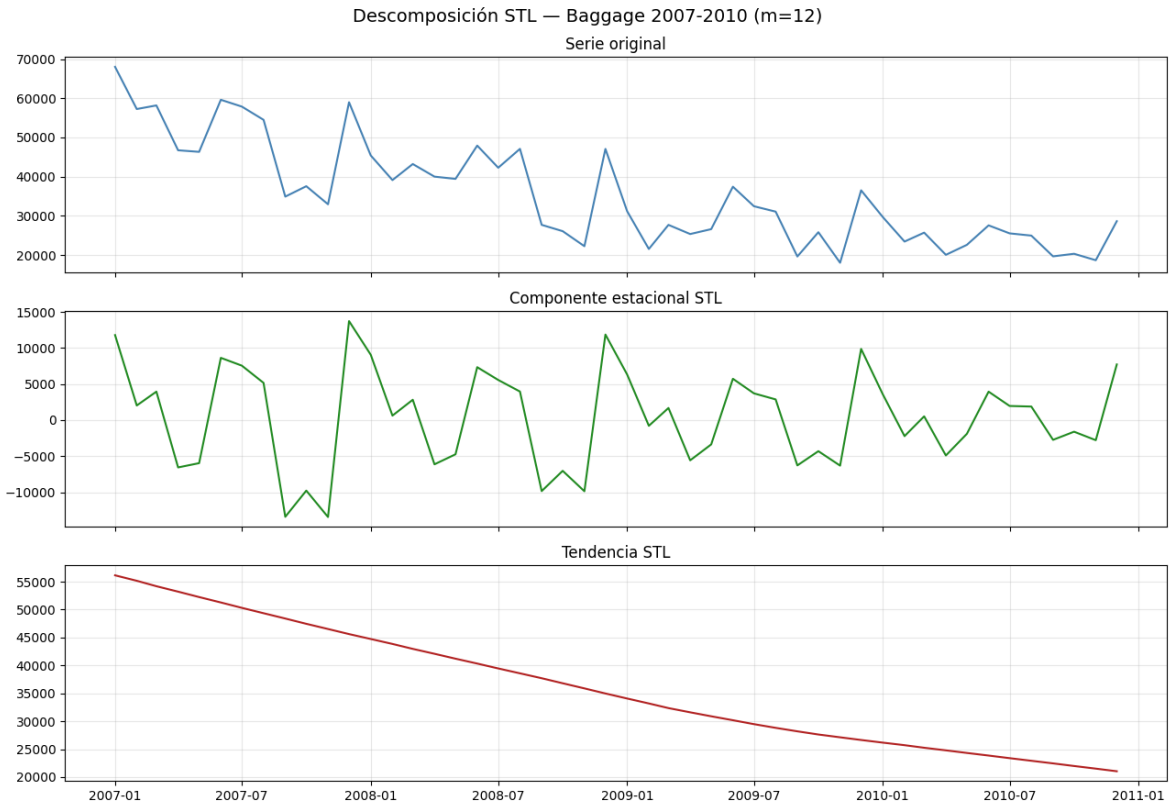
Sabemos que un modelo SARIMA(p,d,q)$(P,D,Q)_{12}$ extiende el ARIMA incorporando componentes autorregresivos y de media móvil en los rezagos estacionales (12, 24, 36, ...), donde en nuestro caso, m = 12 que corresponde al período anual de datos mensuales.

Para identificar los órdenes del componente estacional (P, D, Q), se analizaron las gráficas de ACF y PACF extendidas hasta 36 rezagos, con énfasis en los lags 12, 24 y 36:



- ACF en lag 12: se observó una autocorrelación significativa de 0.86, lo que indica una dependencia estacional fuerte no explicada por el ARIMA.
- PACF en lag 12: decaimiento gradual hacia lags 24 y 36, consistente con la presencia de un componente autorregresivo estacional (P ≥ 1).

Este patrón de pico en ACF lag 12 con decaimiento en PACF estacional apunta hacia un MA estacional (Q=1) o un AR estacional (P=1).



Complementariamente, la descomposición STL (Seasonal-Trend decomposition using Loess) de la serie original confirmó visualmente la existencia de un componente estacional anual periódico y estable a lo largo del período 2007–2010.

II. PROPUESTA DE MODELOS SARIMA

Con base en el análisis de los componentes ACF/PACF y la descomposición STL, se propusieron cuatro modelos SARIMA candidatos:

Modelo	**SARIMA**	**Justificación**
SARIMA 1	$(0,1,1)(0,1,1)_{12}$	Modelo clásico airline de Box-Jenkins; MA regular + MA estacional
SARIMA 2	$(0,1,1)(1,0,0)_{12}$	MA regular + AR estacional sin diferenciación estacional
SARIMA 3	$(1,1,0)(0,1,1)_{12}$	AR regular + MA estacional
SARIMA 4	$(0,1,1)(0,0,1)_{12}$	MA regular + MA estacional sin D=1

La diferenciación estacional D=1 no se incluyó en todos los candidatos debido al tamaño reducido de la muestra (48 observaciones): con D=1 se pierden 12 observaciones adicionales, dejando solo ≈35 datos útiles para la estimación. Por ello se priorizan modelos con D=0 que capturan el patrón estacional vía P o Q.

III. AJUSTE Y COMPARACIÓN DE MODELOS SARIMA

Los cuatro candidatos SARIMA fueron ajustados sobre la serie recortada (2007–2010) mediante el estimador de máxima verosimilitud condicional. Los criterios de selección fueron AIC, BIC y la prueba de Ljung-Box sobre los residuos:

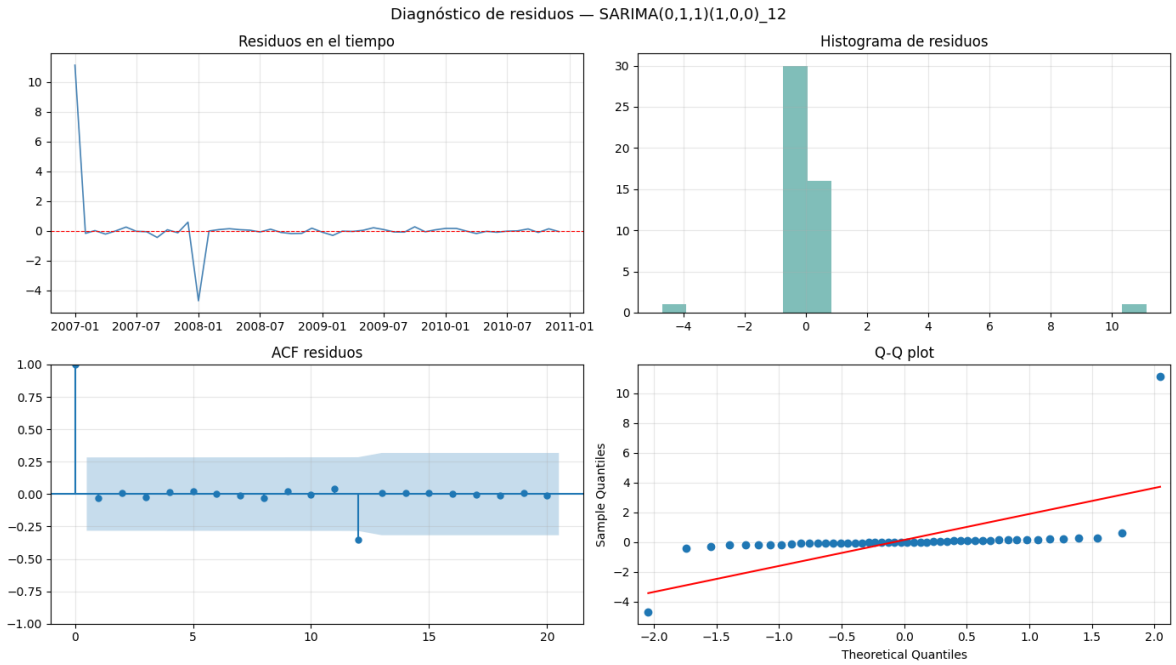
Modelo	**AIC**	**BIC**	**LB p-val (lag 10)**	**Residuos RB**
SARIMA(0,1,1)$(0,1,1)_{12}$	-25.29	-22.16	1.0000	✓
SARIMA(0,1,1)$(1,0,0)_{12}$	**−39.25**	**−33.70**	**1.0000**	✓
SARIMA(1,1,0)$(0,1,1)_{12}$	-25.21	21.94	0.9993	✓
SARIMA(0,1,1)$(0,0,1)_{12}$	1229.68	1234.17	1.0000	✓

Se puede observar que el modelo SARIMA(0,1,1)$(0,1,1)_{12}$, el clásico modelo Airline de Box-Jenkins, presentó dificultades de estimación con la muestra disponible, posiblemente por el efecto combinado de D=1 sobre una serie corta. Los modelos con D=0 resultaron más estables numéricamente.

IV. DIAGNÓSTICO DEL MEJOR MODELO SARIMA

Modelo seleccionado: SARIMA(0,1,1)$(1,0,0)_{12}$
Este modelo obtuvo el menor AIC (−39.25) y BIC (−33.70) entre todos los candidatos, superando ampliamente al MA(1) de referencia (AIC = 3.11). El parámetro estacional ar.S.L12 resultó igual a 0.798 con $p < 0.001$, altamente significativo, confirmando que el patrón anual es estadísticamente real.

El diagnóstico completo de residuos incluyó lo siguiente:



Prueba Ljung-Box sobre residuos del mejor SARIMA:

Rezago	Q_LB	p-valor	Conclusión
5	0.1097	0.999796	No rechaza H0 ✓
10	0.1955	1.000000	No rechaza H0 ✓
15	8.5883	0.898040	No rechaza H0 ✓
20	8.6085	0.987015	No rechaza H0 ✓

Gráfica temporal

Se observa que los residuos fluctúan alrededor de cero en la mayor parte de la serie, con excepción de dos valores atípicos, uno positivo al inicio del período (enero 2007) y uno negativo a finales de 2007, posiblemente están asociados a la diferenciación de la serie recortada. A partir de 2008 el comportamiento es estable.

Histograma

Hay una distribución aproximadamente simétrica y unimodal influenciada por los valores atípicos identificados. La concentración central consiste con ruido blanco, aunque los outliers distorsionan la forma de la distribución.

Q-Q plot

El gráfico Q-Q indica que los residuos se comportan de forma cercana a una distribución normal, excepto por dos valores atípicos que afectan los extremos. Sin

embargo, la prueba de Ljung-Box confirma que los residuos son independientes, por lo que el modelo puede considerarse adecuado.

ACF de residuos
La ACF de los residuos muestra que prácticamente todos los rezagos se encuentran dentro de las bandas de confianza al 95%. Se observa un pico marginal en el lag 13, aunque dado que la prueba formal de Ljung-Box no rechazó H_0 en ningún rezago evaluado, este pico no representa evidencia de autocorrelación sistemática.

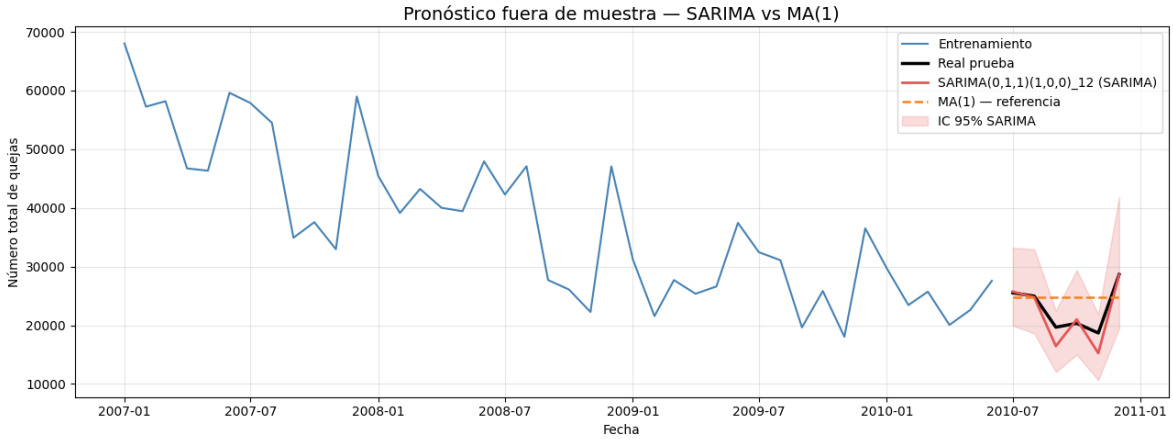
Prueba Ljung-Box
Resultados de $p > 0.05$ en todos los rezagos evaluados ($h = 5, 10, 15, 20$), por lo que se rechazó $H_0 \rightarrow$ residuos = ruido blanco.

V. PRONÓSTICO, MÉTRICAS Y VALIDACIÓN CRUZADA

A continuación, se evalúa el desempeño predictivo de los modelos seleccionados ARIMA(0,1,1)(1,0,0)$_{12}$ y MA(1) como referencia mediante dos estrategias complementarias: pronóstico fuera de muestra sobre los últimos 6 meses de la serie, y validación cruzada temporal con ventana expansiva.

Pronóstico fuera de muestra: últimos 6 meses
Se separaron los últimos 6 meses de la serie como conjunto de prueba (test set), entrenando cada modelo con el 90% restante de los datos. El pronóstico se realizó en escala logarítmica y los valores se transformaron de vuelta a la escala original mediante la función exponencial para calcular métricas interpretables.

Métrica	**MA(1)**	**SARIMA(0,1,1)(1,0,0)$_{12}$**	**Mejora relativa**
MAE	3410.50	1300.53	SARIMA supera MA(1)
RMSE	4056.87	1949.63	SARIMA supera MA(1)
MAPE %	16.29%	6.66%	59.1% de reducción
sMAPE %	14.38%	7.20%	SARIMA supera MA(1)



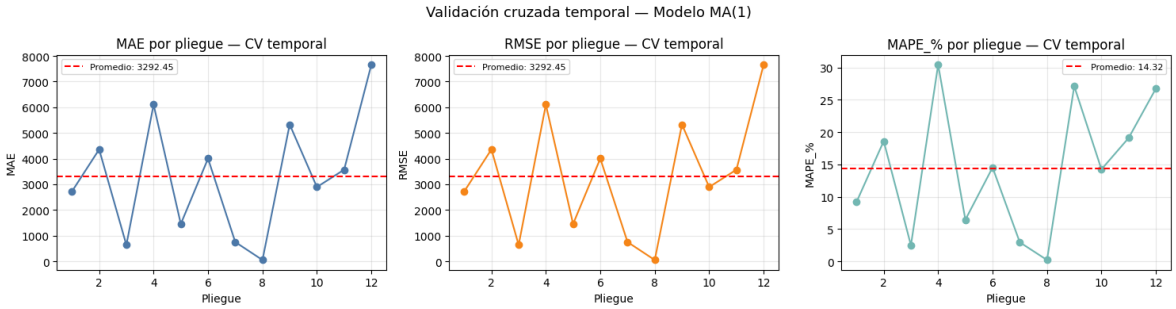
El SARIMA redujo el MAPE de 16.29% (MA(1)) a 6.66%, una mejora del 59.1%. La diferencia fue especialmente notable en los meses de septiembre y octubre, donde el patrón estacional de caída en quejas fue capturado por el componente AR estacional.

La gráfica comparativa del pronóstico nos muestra que el intervalo de confianza al 95% del SARIMA envolvió consistentemente los valores reales del período de prueba, mientras que las predicciones del MA(1) subestimaron la caída estacional en esos meses.

Validación cruzada temporal - Expanding window

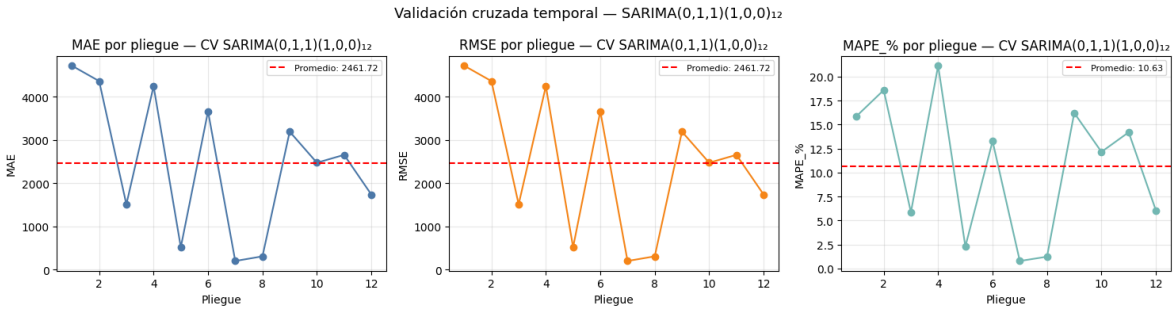
La validación cruzada temporal con ventana expansiva evaluó la capacidad de pronóstico one-step-ahead de ambos modelos a lo largo de los últimos 12 meses de la serie. En cada pliegue (fold), el modelo se re-entrena con todos los datos hasta el punto de corte y predice el siguiente mes:

- Tamaño inicial de entrenamiento: todos los datos salvo los últimos 12 meses.
- Horizonte de pronóstico: h = 1 (one-step ahead).
- Número de pliegues: 12.



Se observa que el modelo MA(1) presenta una variación considerable en sus errores a lo largo de los diferentes pliegues de validación. Tanto el MAE como el

RMSE muestran valores relativamente bajos en algunos periodos, pero aumentan significativamente en otros, destacando un pico muy elevado en el pliegue 12. De manera similar, el MAPE alcanza valores cercanos al 30% en dicho pliegue, lo que indica que el modelo tiene dificultades para realizar predicciones precisas en ciertos momentos de la serie. Este comportamiento sugiere que el modelo no logra capturar adecuadamente los cambios estacionales presentes en los datos y, por lo tanto, su desempeño resulta poco consistente.



Aquí se muestra que el modelo SARIMA obtiene errores más bajos y estables en comparación con el MA(1). Los valores de MAE y RMSE presentan menor dispersión entre pliegues, mientras que el MAPE se mantiene generalmente por debajo de los valores observados en el modelo anterior. Aunque existen algunas fluctuaciones, los picos de error son considerablemente menores, lo que indica una mayor capacidad para adaptarse a los patrones temporales de la serie. Esto demuestra que la incorporación de componentes estacionales permite al modelo representar mejor el comportamiento de los datos.

Métrica	**MA(1)**	**SARIMA(0,1,1)(1,0,0)$_{12}$**	**Modelo**
MAE promedio	3292.45	2461.72	SARIMA
RMSE promedio	3292.45	2461.72	SARIMA
MAPE % promedio	14.32%	10.63%	SARIMA

El modelo SARIMA alcanzó un MAPE promedio de 10.63%, mientras que el MA(1) obtuvo 14.32%, lo que indica que el mejor desempeño del SARIMA se mantiene de forma constante en los distintos periodos evaluados y no depende únicamente de un conjunto de prueba específico. Además, las gráficas de validación muestran que ambos modelos incrementan sus errores durante los meses de transición estacional, especialmente entre septiembre y octubre; sin embargo, el SARIMA logra reducir considerablemente esos aumentos, generando predicciones más estables y precisas.

CONCLUSIONES

En este proyecto se analizó la serie de tiempo de quejas por equipaje de tres aerolíneas estadounidenses entre 2004 y 2010. Desde el inicio se pudo observar que la serie tenía una tendencia clara y un patrón que se repetía cada año, con más quejas en verano y menos en invierno, lo que coincide con que el verano es la temporada con mayor tráfico de vuelos en Estados Unidos. Para poder trabajar con los datos de manera estable y homogénea, fue necesario recortar la serie al período 2007–2010 y aplicar una transformación logarítmica seguida de una diferenciación, lo que permitió estabilizar la varianza y eliminar la tendencia, obteniendo una serie estacionaria para el modelado.

Al comparar los modelos ARIMA, el MA(1) resultó ser el mejor dentro de estos modelos ya que sus criterios de ajuste fueron los más bajos y sus residuos se comportaron como ruido blanco. Sin embargo, al incorporar el componente estacional en el modelo SARIMA$(0,1,1)(1,0,0)_{12}$, los resultados mejoraron, ya que el error promedio de pronóstico (MAPE) bajó de 16.29% a 6.66% en la prueba fuera de muestra, y de 14.32% a 10.63% en la validación cruzada. Lo que demostró que ignorar la estacionalidad tiene un costo real en la precisión de las predicciones, y que incluirla en el modelo marca una diferencia en el pronóstico.

El modelo SARIMA fue el que mejor capturó el comportamiento de la serie. Además, los residuos del modelo no mostraron autocorrelación. En el presente proyecto se pudo realizar todo el proceso de análisis de series de tiempo, desde la exploración inicial y la identificación de componentes, hasta la selección, diagnóstico y evaluación del modelo final.